# Clasificación multietiqueta de anomalías de rodilla en resonancia magnética con supervisión débil derivada de informes multilingües

Anónimo 1 Anónimo 2 Anónimo 3 Anónimo 4 Anónimo 5
Facultad de Ingeniería Industrial y de Sistemas
Universidad Nacional de Ingeniería

31 de octubre de 2026

**Abstract**

Se aborda la predicción simultánea de doce hallazgos clínicos en estudios de resonancia magnética de rodilla del conjunto RSNA Knee Abnormality Detection, donde solo 58 de 4 407 estudios tienen etiquetas verificadas por un radiólogo y el resto únicamente dispone de su informe en texto libre, redactado en nueve idiomas. Se construye un pipeline de extracción de etiquetas débiles basado en reglas con detección de negación y traducción automática selectiva, que alcanza un 74.3 % de acuerdo contra las etiquetas doradas, con una tasa de ruido estimada del 25.7 %. Sobre esas etiquetas se entrenan dos arquitecturas 2.5D con agregación por conjuntos: una red Inception implementada desde cero y una ResNet-50 preentrenada en ImageNet. ResNet-50 con agregación por promedio, el modelo del análisis detallado, alcanza un AUC-ROC macro de 0.708 (IC95 % $[0.662, 0.755]$) sobre los dorados; otra configuración con más datos y atención por etiqueta llega a 0.761, el mayor valor puntual, con intervalo solapado. Un bootstrap pareado muestra que solo dos de siete diferencias estudiadas en la ablación son estadísticamente significativas, y que las dos son decisiones sobre los *datos* (el preentrenamiento en ImageNet y el plano de la resonancia) y no sobre la arquitectura. Se documenta además que una versión anterior de este trabajo reportaba como significativa una ablación que no lo era, por entrenar en GPU sin fijar los kernels: dos corridas idénticas divergían hasta 0.041 de AUC, más que cuatro de las siete diferencias que se miden. El análisis con Grad-CAM revela que la confianza del modelo correlaciona con la plausibilidad anatómica de su evidencia, y la evaluación por idioma documenta un sesgo lingüístico marcado que persiste tras la mitigación.

## 1 Motivación

La resonancia magnética es el estudio de referencia para evaluar lesiones de ligamentos, meniscos y cartílago de la rodilla, pero su interpretación depende de radiólogos musculoesqueléticos y está sujeta a variabilidad inter-observador. Fuera de los grandes centros la demora entre el estudio y su informe se mide en semanas, y un clasificador automático podría priorizar estudios o actuar como segunda lectura.

La dificultad no es la que suele plantearse en los conjuntos curados de visión por computadora. Acá la supervisión disponible es el obstáculo principal: de 4 407 estudios de entrenamiento, solo 58 cuentan con las doce etiquetas verificadas por un radiólogo. Los 4 349 restantes aportan únicamente el informe original en texto libre, redactado en uno de nueve idiomas por profesionales de 16 centros en cinco continentes.

Esa asimetría desplaza el trabajo hacia una pregunta que rara vez se formula: antes de entrenar cualquier red hay que construir las etiquetas y cuantificar cuán sucias quedaron. Este informe sostiene que esa cuantificación (y no la elección de arquitectura) es lo que gobierna el resultado final.

## 2 Trabajos relacionados

**Arquitecturas convolucionales.** La progresión de LeNet [6] a AlexNet [5] y VGG [11] estableció que apilar convoluciones con reducciones sucesivas de resolución produce representaciones jerárquicas útiles, al costo de un crecimiento rápido en parámetros. Inception [12] aborda ese costo con ramas paralelas de distinto tamaño de núcleo; las redes residuales [3] atacan otro problema (la degradación del entrenamiento con la profundidad) mediante conexiones de salto. El preentrenamiento sobre ImageNet [2] es la práctica habitual con conjuntos de destino pequeños, y acá resulta una de las dos únicas decisiones significativas (Sección 5.7).

**Agregación de instancias.** La predicción es por estudio, pero la red observa cortes. El marco de aprendizaje de múltiples instancias con atención [4] formula esa agregación como una suma ponderada cuyos pesos la red aprende, con una compuerta multiplicativa que suprime instancias irrelevantes. Este trabajo sigue esa formulación; la ablación muestra que, con 416 estudios de entrenamiento, un promedio sin parámetros queda por delante sin que la diferencia alcance significancia.

**Interpretabilidad y desbalance.** Grad-CAM [10] produce mapas de localización a partir del gradiente de una salida respecto del último mapa convolucional, sin modificar la arquitectura ni reentrenar; se emplea aquí para juzgar si las regiones en que se apoya el modelo son anatómicamente plausibles. Para el desbalance, la pérdida focal [7] reescala cada término por $(1 - p_t)^{\gamma}$ para reducir la contribución de los ejemplos ya resueltos, y se evalúa junto con una ponderación por prevalencia inversa.

**Extracción de información desde texto clínico.** NegEx [1] resuelve el problema central de leer informes médicos: distinguir un hallazgo afirmado de uno explícitamente descartado, mediante disparadores léxicos dentro de una ventana alrededor del término. La Sección 5.1 cuantifica cuánto cambia el resultado al incorporarlo. Para los informes en idiomas que el extractor no lee de forma nativa se emplea NLLB-200 [8].

## 3 Conjunto de datos

El conjunto RSNA Knee Abnormality Detection [9] contiene 819 640 archivos DICOM (569.76 GB) correspondientes a 4 407 estudios de entrenamiento. Cada estudio incluye entre 3 y 14 series, con una mediana de 28 cortes por serie.

La detección automática de idioma sobre los informes arroja nueve lenguas: inglés (39.4 %), español (15.5 %), turco (12.4 %), croata (9.2 %), griego (7.3 %), alemán (5.9 %), búlgaro (5.0 %), neerlandés (3.5 %) y francés (1.8 %). Dos de ellas no emplean alfabeto latino.

La heterogeneidad técnica de las imágenes es considerable. Sobre una muestra de 764 cortes se midieron diez resoluciones distintas entre $320 \times 320$ y $1024 \times 1024$, espaciados de píxel entre 0.146 y 0.562 mm (un factor de cuatro), campos de visión físicos de 130 a 240 mm, ocho fabricantes, intensidades de campo de 1.5 T y 3 T, y profundidades de 12 y 16 bits. La etiqueta `Laterality` está ausente o vacía en el 54 % de los cortes, y el campo `SeriesDescription` resulta inutilizable como filtro: presenta 21 valores distintos, incluido el literal `DummySeriesDesc!` en el 10 % de los casos.

## 4 Metodología

### 4.1 Extracción de etiquetas débiles

El extractor procesa cada informe oración por oración, en lugar de sobre el texto completo: operar sobre el informe entero permitiría que un término patológico de una oración se asociara con una estructura anatómica mencionada en otra.

Siete de las doce etiquetas exigen la coincidencia simultánea de un término anatómico y uno patológico dentro de la misma oración. Mencionar el ligamento cruzado anterior no constituye un hallazgo: prácticamente todos los informes lo nombran, habitualmente para declararlo íntegro. Las cinco restantes (derrame articular, sinovitis, quiste de Baker, contusión ósea y fractura) son hallazgos directos cuyo término ya denota la patología.

Sobre cada coincidencia se aplica un clasificador de aserción siguiendo el esquema NegEx [1]: una ventana de seis palabras alrededor del término se examina en busca de disparadores previos (*no*, *without*, *sin*) y posteriores (*is intact*, *not torn*, *conservado*), más un conjunto de expresiones de incertidumbre.

Los informes en los siete idiomas que el extractor no lee de forma nativa se traducen al inglés con NLLB-200-distilled-600M [8], oración por oración. La traducción por oraciones es necesaria porque los informes alcanzan 4 743 caracteres, más de lo que el modelo procesa en una pasada, y además preserva la estructura sobre la que opera el extractor.

Extender el diccionario de términos a los siete idiomas restantes no habría resuelto el problema. El detector de negación opera sobre palabras separadas dentro de una ventana, y el turco niega mediante un sufijo (*yırtılmamış*, "no desgarrado"), mientras que el griego y el búlgaro añaden un alfabeto distinto. Traducir el texto completo convierte nueve problemas de negación en el único que ya está resuelto y medido.

### 4.2 Preprocesamiento

Dada la dispersión de espaciados de píxel documentada en la Sección 3, redimensionar directamente a $224 \times 224$ entregaría la misma estructura anatómica a escalas físicas dispares: la red debería aprender configuraciones de escáner antes de poder aprender anatomía.

El pipeline recorta en consecuencia una ventana de 130 mm *físicos*, empleando el espaciado de píxel del encabezado DICOM, y redimensiona después. La intensidad se normaliza por corte entre sus percentiles 1 y 99, dado que la resonancia magnética carece de unidades absolutas: el mismo tejido registra 636 en un escáner y 2 781 en otro. La lateralidad se resuelve con la etiqueta `Laterality` cuando está presente y, en su defecto, mediante el signo de la coordenada $x$ del sistema de coordenadas del paciente; cuando ninguna fuente responde, la serie se deja sin modificar antes que invertirla por conjetura.

De cada serie se descarta el 20 % de cortes en cada extremo (mayormente aire y diáfisis) y de la banda central se extraen ocho grupos de tres cortes contiguos, uniformemente espaciados. La elección de tres canales es deliberada: los pesos de ImageNet esperan exactamente tres, de modo que la primera convolución preentrenada se carga sin modificación alguna.

No se emplea procesamiento volumétrico 3D. El espaciado entre cortes (2.875 mm) supera entre 6 y 20 veces al espaciado dentro del corte, de modo que el volumen es marcadamente anisotrópico: un núcleo $3 \times 3 \times 3$ mezclaría 1.5 mm en el plano con 8.6 mm entre cortes.

### 4.3 Selección del subconjunto

Se trabaja con 576 estudios, dentro del rango recomendado. Un muestreo aleatorio no sería adecuado: con 182 positivos de fractura entre 4 407 estudios, una extracción aleatoria de 600 contendría unos 25, insuficientes tanto para aprender como para medir.

El muestreo procede en tres pasadas. Primero se incorporan todos los estudios dorados, que constituyen el conjunto de prueba. Luego se completan cuotas por etiqueta, recorriéndolas de la más rara a la más frecuente; el orden importa, porque un estudio positivo en fractura suele serlo también en algún hallazgo común, de modo que las etiquetas frecuentes se completan solas mientras que las raras nunca lo harían. El resto se extrae al azar, para que la muestra represente la distribución real y no exclusivamente patología. La muestra resultante garantiza al menos 73 positivos por etiqueta.

Se excluyen los estudios en que el extractor no halló evidencia alguna. No se trata de rodillas sanas, sino de informes que el extractor no pudo leer; entrenar con ellos equivaldría a enseñarle al modelo que estudios con patología real son completamente negativos.

### 4.4 Arquitecturas

Ambos modelos comparten toda la cadena excepto el codificador:

$$(B, 8, 3, 224, 224) \xrightarrow{\text{codificador}} (B, 8, D) \xrightarrow{\text{agregación}} (B, D) \xrightarrow{\text{cabeza}} 12 \text{ logits}$$

El **modelo A** emplea un codificador Inception escrito desde cero, con cuatro bloques y 0.58 M parámetros en el codificador (0.7 M en el modelo completo). Se eligió Inception sobre una pila residual por una razón vinculada al dominio: sus ramas paralelas observan campos receptivos de $1 \times 1$, $3 \times 3$ y $5 \times 5$ a la misma profundidad, y los hallazgos de rodilla se manifiestan a escalas muy dispares: una rotura meniscal abarca milímetros, un derrame ocupa la cápsula articular. Con 576 estudios, capturar ambas escalas sin profundizar resulta más valioso que la profundidad en sí. Las reducciones $1 \times 1$ previas a las ramas $3 \times 3$ y $5 \times 5$ son precisamente lo que contiene el conteo de parámetros.

El **modelo B** emplea ResNet-50 con pesos de ImageNet (24.1 M parámetros), descartando su cabeza de clasificación y conservando la característica agrupada de 2 048 dimensiones.

La agregación y la cabeza multietiqueta son idénticas en ambos. La agregación por atención sigue la formulación con compuerta de Ilse et al. [4]: una red pequeña puntúa cada grupo, los puntajes se normalizan con softmax y el embedding del estudio es su suma ponderada. Un promedio diluiría el hallazgo (una rotura meniscal abarca dos o tres cortes de treinta) y un máximo descartaría la evidencia corroborante además de resultar frágil ante un corte ruidoso.

### 4.5 Atención por etiqueta y reparto por plano

Una atención compartida obliga a las doce etiquetas a ponderar los cortes de la misma manera, y los hallazgos no viven en los mismos: un derrame ocupa la cápsula, una rotura meniscal dos o tres cortes centrales. Las configuraciones C–E usan doce atenciones. El codificador y la proyección siguen compartidos (hasta ahí nada depende de qué se busca) y la separación ocurre en la compuerta, de modo que cada etiqueta elige sus grupos sin multiplicar el costo del codificador.

El reparto por plano responde a que una estructura se ve o no según la dirección del corte. La artrosis patelofemoral es el desgaste entre la rótula y el surco femoral: el corte axial muestra esa superficie completa y el coronal la superpone al fémur, y medido sobre validación la etiqueta gana 0.060 de AUC al cambiar de plano —el mayor efecto de este trabajo. El menisco lateral pierde 0.033, coherente con ser una estructura horizontal que el axial corta en su propio plano. La configuración E entrena cuatro modelos y cada etiqueta se predice con el suyo. El reparto se decidió sobre validación; los dorados se usaron una sola vez, ya fijado.

### 4.6 Protocolo de evaluación

Las decisiones de arquitectura, función de pérdida, agregación, número de épocas y umbral se toman exclusivamente mediante validación sobre las etiquetas débiles (416 estudios de entrenamiento, 104 de validación). De los 58 estudios con etiqueta de radiólogo, 2 no aportan una serie sagital sensible a líquido con supresión grasa y quedan fuera del subconjunto preprocesado, de modo que la prueba se realiza sobre los 56 restantes, una única vez, al final, para la cifra que se reporta.

Esta separación no es una formalidad. Con 56 estudios de prueba y nueve positivos de ligamento colateral medial, seleccionar el modelo contra ese conjunto no mediría generalización sino el grado de sobreajuste de la propia selección, y la cifra posterior se informaría sobre los mismos datos empleados para elegir. La regla se mantiene por su propio fundamento y no por una observación empírica: una versión anterior de este trabajo la ilustraba con una inversión del ordenamiento entre ambos conjuntos que, al hacer el entrenamiento reproducible, resultó ser un artefacto (Sección 5.5).

Todo intervalo de confianza se obtiene por bootstrap sobre 2 000 remuestreos. Las comparaciones entre configuraciones emplean bootstrap *pareado*: ambos modelos se evalúan sobre los mismos estudios, de modo que sus errores están correlacionados y comparar intervalos independientes resultaría excesivamente conservador.

## 5 Experimentos y resultados

### 5.1 Extracción de etiquetas débiles

Un buscador de términos sin tratamiento de negación alcanza apenas un 48.3 % de acuerdo en derrame articular y produce 112 falsos positivos sobre 58 estudios. La causa es estructural: los informes radiológicos enumeran tanto lo que el radiólogo encontró como lo que descartó (*"ACL is intact"*, *"no fracture is seen"*, *"medial meniscus is not torn"*), de modo que un buscador de términos marca positivo precisamente donde el informe declara la estructura sana.

Se compararon cuatro estrategias de traducción sobre los mismos 58 dorados. Sin traducir, el acuerdo macro es 72.1 % ($F_1$ 0.512, ruido 27.9 %); traducir todo lo lleva a 74.0 % ($F_1$ 0.556, ruido 26.0 %); y el esquema híbrido (traducir salvo inglés y español) a 74.3 % ($F_1$ 0.589), con la tasa de ruido en 25.7 %. Los modelos se entrenaron con las etiquetas de este híbrido, de modo que 25.7 % es el ruido de entrenamiento y 26.0 % una medición del estudio de traducción. Traducir todo y traducir salvo inglés dan el mismo resultado hasta la tercera cifra: traducir inglés a inglés no cambia nada medible, y lo que mueve la aguja es exclusivamente *no* traducir el español.

La mejora del esquema híbrido sobre la línea base es de $+0.076$ en $F_1$ macro, con IC95 % $[+0.039, +0.127]$ por bootstrap pareado sobre estudios: el intervalo de la diferencia no cruza cero, aunque los sueltos se solapen.

El español se tradujo deliberadamente como experimento de control. Puesto que el extractor lo lee de forma nativa con $F_1$ 0.48, una traducción que no degradara información debería arrojar un valor comparable. El resultado observado es 0.29, una caída de 19 puntos que confirma que el traductor deteriora la terminología médica y justifica excluir el español del esquema final. El inglés, que no se traduce, permanece en 0.66 y verifica que el pipeline no altera lo que no debe.

**Cuadro 1:** $F_1$ macro por idioma sobre los estudios dorados, antes y después de la traducción, y proporción de estudios sin ninguna etiqueta positiva sobre el conjunto completo.

| Idioma | $n$ dorados | $F_1$ macro | | Sin etiqueta | |
|---|---|---|---|---|---|
| | | Antes | Después | Antes | Después |
| Inglés | 28 | 0.66 | 0.66 | 11.5 % | 11.5 % |
| Español | 10 | 0.48 | 0.29 | 18.9 % | 18.9 % |
| Turco | 6 | 0.04 | 0.34 | 87.5 % | 25.1 % |
| Croata | 4 | 0.00 | 0.21 | 93.1 % | 9.4 % |
| Griego | 3 | 0.00 | 0.11 | 90.3 % | 54.2 % |
| Búlgaro | 3 | 0.00 | 0.32 | 99.5 % | 10.9 % |
| Neerlandés | 2 | 0.06 | 0.44 | 94.8 % | 17.6 % |
| Alemán | 2 | 0.08 | 0.19 | 63.7 % | 26.7 % |

La proporción global de estudios sin ninguna etiqueta positiva desciende del 46.8 % al 18.3 % (807 de 4 407).

El extractor subdetecta, pero no de forma uniforme, y la diferencia importa. El cociente entre la prevalencia extraída sobre los 4 407 estudios y la observada en los dorados va de 1.02 en menisco medial (45.6 % frente a 44.8 %, no subdetecta nada) a 0.22 en sinovitis. Las tres peores no fallan por el mismo motivo: sinovitis es la única donde el recall medido también se hunde (0.37), mientras que fractura tiene recall 0.78 y extrae poco simplemente porque es poco prevalente. Esa distinción separa "la etiqueta es ruidosa" de "la etiqueta es rara", que son dos problemas distintos con soluciones distintas.

### 5.2 Curvas de entrenamiento

El sobreajuste es visible de inmediato. La razón entre la pérdida final de validación y la de entrenamiento es de $5.7\times$ para ResNet-50 con promedio, $3.2\times$ con atención y $1.1\times$ para Inception. Esta última mantiene ambas curvas juntas por falta de capacidad para separarlas, no por diseño, y obtiene el AUC más bajo de las tres.

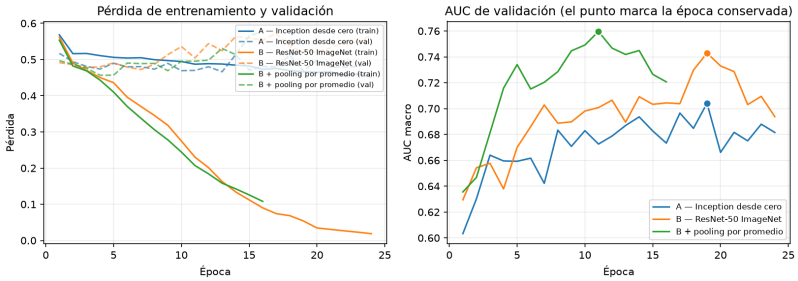



**Figura 1:** Izquierda: pérdida de entrenamiento (línea continua) y de validación (discontinua). Derecha: AUC macro de validación; el punto marca la época que la detención temprana conserva.

### 5.3 Comparación de las dos arquitecturas

**Cuadro 2:** Resultados sobre los estudios dorados. El umbral se selecciona en validación y se aplica sin modificación. Los dos bloques son regímenes de datos distintos y no se comparan entre sí; dentro de cada uno solo cambia la arquitectura.

| Configuración | Parám. | AUC macro | IC95 % | $F_1$ | Umbral |
|---|---|---|---|---|---|
| *576 estudios, 8 grupos, una sola vista sagital* | | | | | |
| A — Inception desde cero | 0.7 M | 0.628 | $[0.569, 0.687]$ | 0.484 | 0.25 |
| B — ResNet-50 ImageNet | 24.1 M | 0.646 | $[0.579, 0.703]$ | 0.490 | 0.25 |
| B + agregación por promedio | 23.5 M | 0.708 | $[0.662, 0.755]$ | 0.560 | 0.20 |
| *4 407 estudios, 64 grupos, atención por etiqueta* | | | | | |
| C — Inception, un modelo de 12 | 1.3 M | 0.638 | $[0.581, 0.693]$ | 0.500 | 0.15 |
| D — Inception por caras | $3\times$1.3 M | 0.658 | $[0.607, 0.709]$ | 0.487 | 0.20 |
| E — ResNet-50 por caras | $4\times$26.9 M | **0.761** | $[0.715, 0.810]$ | **0.588** | 0.20 |

La configuración E alcanza el mayor AUC macro puntual sobre los dorados, 0.761, con $F_1$ de 0.588 al umbral 0.20 elegido en validación; su intervalo $[0.715, 0.810]$ se solapa con el de ResNet-50 con promedio ($[0.662, 0.755]$), de modo que el margen sobre este no es significativo. El umbral queda muy por debajo de 0.5, coherente con prevalencias del 12.2 % al 50.7 %: un umbral de 0.5 descartaría casi todos los positivos de las etiquetas raras.

Entre las dos arquitecturas del entregable #2, ResNet-50 con ImageNet supera a la Inception escrita desde cero por 0.018 de AUC, y el bootstrap pareado deja ese margen dentro del ruido ($[-0.098, +0.058]$): con 56 estudios de prueba no se puede afirmar. El segundo bloque cambia el veredicto, y el cambio proviene del régimen y no de la arquitectura. Con 4 407 estudios, ResNet-50 por caras supera a Inception por caras en 0.103 con intervalos que no se solapan ($[0.715, 0.810]$ frente a $[0.607, 0.709]$), de modo que acá la diferencia sí se sostiene. El empate del primer bloque describía un conjunto demasiado pequeño para que el preentrenamiento rindiera, no una equivalencia entre los modelos.

### 5.4 Desglose por etiqueta

Tres de las doce etiquetas no se distinguen del azar: su intervalo incluye 0.5. El ancho medio del intervalo por etiqueta es 0.302 frente a 0.093 del macro, un resumen 3.3 veces más estrecho que cualquiera de sus componentes por pura aritmética, no por mayor certeza sobre ningún hallazgo concreto. Los dos casos extremos fallan por razones distintas: el menisco lateral tiene 23 positivos, suficientes, y aun así da 0.531 (el modelo no lo detecta), mientras que el ligamento colateral medial tiene nueve y su intervalo abarca 0.39 puntos, de modo que ni siquiera se puede decir si lo detecta.

### 5.5 Reproducibilidad del entrenamiento

Dos entrenamientos de la misma configuración, con la misma semilla y los mismos datos, divergían desde la primera época y llegaban a mejores AUC de 0.6501 y 0.6801; fijando los kernels, coinciden

**Cuadro 3:** Desglose por etiqueta sobre los estudios dorados. Las tres columnas de AUC corresponden a Inception (A), ResNet-50 (B) y ResNet-50 con promedio; el intervalo y la matriz de confusión son de esta última, al umbral 0.20 elegido en validación. Un asterisco marca los intervalos que incluyen 0.5: son 3 de 12, es decir hallazgos que no se distinguen del azar.

| Etiqueta | Pos. | A | B | Mejor (IC95 %) | TP | FP | FN | TN | $F_1$ |
|---|---|---|---|---|---|---|---|---|---|
| Lig. cruzado ant. | 23 | 0.714 | 0.706 | 0.776 $[0.64, 0.89]$ | 20 | 17 | 3 | 16 | 0.667 |
| Lig. colateral med. | 9 | 0.496 | 0.520 | 0.638 $[0.44, 0.83]^*$ | 6 | 20 | 3 | 27 | 0.343 |
| Menisco medial | 24 | 0.611 | 0.680 | 0.734 $[0.59, 0.86]$ | 22 | 18 | 2 | 14 | 0.687 |
| Menisco lateral | 23 | 0.545 | 0.497 | 0.531 $[0.38, 0.69]^*$ | 16 | 18 | 7 | 15 | 0.561 |
| Osteoartrosis med. | 15 | 0.680 | 0.720 | 0.816 $[0.68, 0.93]$ | 8 | 4 | 7 | 37 | 0.593 |
| Osteoartrosis lat. | 11 | 0.610 | 0.655 | 0.693 $[0.51, 0.87]$ | 5 | 9 | 6 | 36 | 0.400 |
| Osteoartrosis PF | 20 | 0.589 | 0.618 | 0.704 $[0.55, 0.84]$ | 19 | 31 | 1 | 5 | 0.543 |
| Derrame articular | 34 | 0.749 | 0.729 | 0.619 $[0.46, 0.77]^*$ | 31 | 19 | 3 | 3 | 0.738 |
| Sinovitis | 25 | 0.697 | 0.648 | 0.672 $[0.52, 0.81]$ | 17 | 16 | 8 | 15 | 0.586 |
| Quiste de Baker | 11 | 0.648 | 0.640 | 0.731 $[0.51, 0.91]$ | 6 | 12 | 5 | 33 | 0.414 |
| Contusión ósea | 18 | 0.594 | 0.652 | 0.773 $[0.64, 0.90]$ | 17 | 25 | 1 | 13 | 0.567 |
| Fractura | 17 | 0.605 | 0.689 | 0.813 $[0.67, 0.93]$ | 13 | 12 | 4 | 27 | 0.619 |

bit a bit (0.6633 y 0.6633). El origen no fue un error de cálculo sino una suposición: que sembrar los generadores basta para que un entrenamiento en GPU sea reproducible. No basta (cuDNN elige sus kernels en tiempo de ejecución y varios acumulan en orden no determinista) y la magnitud importa más que el hecho: la diferencia entre dos corridas idénticas llegó a 0.041 de AUC macro, mayor que cuatro de las siete comparaciones que se reportan más abajo. Mientras los kernels no estén fijados, ninguna distingue el efecto buscado del ruido de ejecución, y el bootstrap no lo advierte: mide la variabilidad del muestreo de estudios, no la de la ejecución.

Todos los resultados de este informe provienen de corridas con `cudnn.deterministic`, `benchmark` desactivado, `use_deterministic_algorithms` y `CUBLAS_WORKSPACE_CONFIG` fijado antes de crear el contexto de CUDA. La verificación corre como una etapa del pipeline y falla si las dos corridas no coinciden bit a bit, a un costo despreciable (2.4 minutos contra 2.2 por corrida).

### 5.6 Validación cruzada

Las primeras decisiones se tomaron sobre una única división 80/20 de los estudios con etiqueta débil. Repetir el entrenamiento sobre cinco pliegues da la escala con la que hay que leer cualquier diferencia medida sobre una sola partición: ResNet-50 con promedio alcanza $0.7354 \pm 0.0125$ de AUC medio entre pliegues, con atención $0.6975 \pm 0.0143$, e Inception con atención $0.6717 \pm 0.0150$. Las tres desviaciones rondan 0.014, de modo que una diferencia menor a unos 0.03 entre configuraciones medida sobre una sola partición no se distingue de la variación entre pliegues. El detalle por pliegue está en `paso3_modelos/validacion_cruzada.json`.

### 5.7 Estudio de ablación

Solo dos de las siete comparaciones alcanzan significancia, y las dos son sobre los datos, no sobre la arquitectura. El preentrenamiento en ImageNet aporta $+0.084$ de AUC ($[+0.002, +0.165]$) y el plano sagital supera al coronal en $+0.056$ ($[+0.005, +0.108]$, sobre los 54 estudios dorados que tienen ambos planos). Ninguna de las cinco decisiones restantes (arquitectura, agregación, función de pérdida en dos variantes y ponderación por clase) produce un efecto que el intervalo distinga de cero.

**La agregación por atención.** El promedio simple supera a la agregación por atención en $+0.062$ de AUC, con el promedio preferido en el 97 % de los remuestreos, pero el intervalo roza el cero ($[-0.001, +0.128]$) y por lo tanto la diferencia no se puede afirmar. La dirección es la esperable si el módulo de atención sobreajusta (introduce parámetros entrenables sobre 416 estudios cuyas etiquetas tienen un 25.7 % de ruido, mientras que un promedio no tiene parámetros y no puede

**Cuadro 4:** Bootstrap pareado sobre los estudios dorados. 2 de 7 diferencias alcanzan significancia, entendida como un intervalo del 95 % que no cruza cero. El bootstrap es *pareado* —remuestrea los mismos estudios para las dos configuraciones— porque comparar dos intervalos independientes tiene mucha menos potencia.

| Comparación | $\Delta$ AUC | IC95 % | $P(A > B)$ | Signif. |
|---|---|---|---|---|
| Inception vs. ResNet-50 | $-0.018$ | $[-0.098, +0.058]$ | 34 % | no |
| Promedio vs. atención | $+0.062$ | $[-0.001, +0.128]$ | 97 % | no |
| ImageNet vs. desde cero | $+0.084$ | $[+0.002, +0.165]$ | 98 % | **sí** |
| Focal vs. BCE (con atención) | $-0.025$ | $[-0.081, +0.034]$ | 20 % | no |
| Focal vs. BCE (con promedio) | $-0.016$ | $[-0.051, +0.016]$ | 16 % | no |
| BCE ponderada vs. BCE | $-0.009$ | $[-0.047, +0.027]$ | 31 % | no |
| Plano sagital vs. coronal | $+0.056$ | $[+0.005, +0.108]$ | 99 % | **sí** |

sobreajustar), y es consistente en validación (0.762 contra 0.724), pero afirmarla con 56 estudios de prueba sería ir más lejos de lo que el dato permite.

Conviene decir explícitamente qué cambió: una versión anterior de este trabajo reportaba esta misma comparación como $+0.103$ con intervalo $[+0.048, +0.159]$ y la presentaba como su hallazgo principal. Ese número provenía de corridas no reproducibles (Sección 5.5). Con el entrenamiento fijado, el efecto es menor y no alcanza significancia. No es que la conclusión anterior fuera falsa: es que nunca estuvo sostenida.

**Las decisiones sobre los datos sí pesan.** Las dos diferencias que sobreviven al test son las que cambian *qué ve* el modelo: de dónde vienen sus pesos iniciales y qué plano se le muestra. Es coherente con lo que ocurre en la extracción de etiquetas, donde la detección de negación y la traducción produjeron los efectos de mayor magnitud de todo el trabajo: con 416 estudios de entrenamiento y un 25.7 % de ruido en las etiquetas, lo que se le da al modelo importa más que cómo está construido. En cambio, ninguna de las tres variantes de pérdida evaluadas (focal con atención, focal con promedio, BCE ponderada) mejora el resultado, y las tres tienen intervalos que cruzan cero.

### 5.8 Interpretabilidad

Se generaron mapas de activación para los tres hallazgos que pide el enunciado, sobre ResNet-50 con promedio. En cada panel, de izquierda a derecha: el corte original, el mapa de activación y la superposición de ambos.

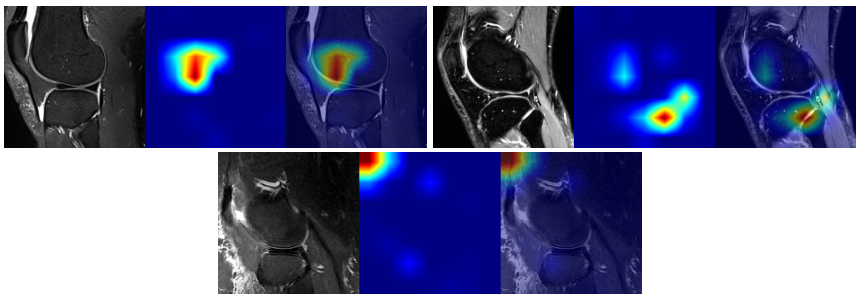


**Figura 2:** Grad-CAM sobre ResNet-50 con promedio. *Arriba*, derrame articular ($p = 0.576$): la activación se concentra en el receso suprapatelar, donde el líquido se acumula. *Centro*, ligamento cruzado anterior ($p = 0.815$): cubre la región intercondílea, donde el ligamento se inserta. *Abajo*, menisco medial ($p = 0.406$): la activación cae fuera de la articulación. Es el caso más incómodo, porque su AUC de 0.734 está entre los mejores: el modelo acierta sin mirar donde debería.

Los dos casos plausibles son también los de mayor probabilidad predicha: el derrame articular activa el receso suprapatelar y el ligamento cruzado anterior la región intercondílea. El menisco medial es el más informativo, y no por fallar: con $p = 0.406$ y umbral 0.20 el modelo lo predice correctamente como positivo, y su AUC de 0.734 está entre los mejores de la tabla. Lo que Grad-CAM muestra

es que esa predicción correcta se apoya en una región que está fuera de la articulación. Ninguna métrica de desempeño podía advertirlo.

Para distinguir un patrón de una coincidencia, el procedimiento se repitió sobre ocho estudios dorados positivos de cada uno de los doce hallazgos, midiendo el centro de masa de la región activada en coordenadas normalizadas.

Solo 3 de los doce hallazgos tienen activación consistente (dispersión del centro de masa menor a 0.20 y ningún caso en el margen, medido en `paso5_ablacion_gradcam/patron_gradcam.json`), y la observación cualitativa de la figura coincide con la medición: el derrame articular y el ligamento cruzado anterior están entre esos tres. En los nueve restantes la evidencia varía demasiado entre casos como para considerarla anatómicamente localizada, y todos presentan al menos un caso cuya activación cae en el margen de la imagen. Dado que el preprocesamiento recorta 130 mm centrados en la rodilla, una activación en el margen no puede corresponder a la articulación.

Esto tiene lectura clínica directa: las predicciones dudosas no son solo inciertas, sino que además se apoyan en regiones que no corresponden a la anatomía del hallazgo, y como los umbrales seleccionados caen entre 0.10 y 0.30, esas predicciones se convierten en positivos.

### 5.9 Desbalance de clases

Las prevalencias en la muestra empleada van del 12.2 % (osteoartrosis del compartimento lateral) al 50.7 % (daño de menisco medial), un factor de cuatro entre extremos.

Se evaluaron dos mitigaciones. La entropía cruzada binaria ponderada asigna a cada etiqueta un peso inversamente proporcional a su prevalencia, con tope en 10 para que una etiqueta casi ausente no desestabilice el entrenamiento. La pérdida focal [7] reduce la contribución de los ejemplos ya resueltos: con $\gamma = 2$ y $\alpha = 0.25$ disminuye 880 veces el aporte de un ejemplo fácil y solo 2.2 veces el de uno difícil.

Ninguna de las dos mejora el AUC macro, y ninguna lo empeora de forma que el test distinga: la ponderada da $\Delta = -0.009$ (IC95 % $[-0.047, +0.027]$) y la focal $\Delta = -0.016$ (IC95 % $[-0.051, +0.016]$). Por etiqueta rara el resultado se reparte sin patrón, y con 56 estudios esas diferencias están dentro del ruido. El desbalance no es la restricción dominante de este problema; el 25.7 % de ruido en las etiquetas de entrenamiento sí lo es.

## 6 Sesgo geográfico y lingüístico

La calidad de la extracción de etiquetas varía de forma pronunciada entre idiomas. Antes de la traducción, el $F_1$ macro iba de 0.66 en inglés a 0.00 en croata, griego y búlgaro: el pipeline producía supervisión utilizable para el 55 % de los estudios y ruido para el 45 % restante, en correlación directa con el país del centro emisor.

La traducción mitiga el problema sin eliminarlo. El griego permanece con un 54.2 % de estudios sin ninguna etiqueta, frente al 11.5 % del inglés. La degradación terminológica del traductor es observable de forma directa: *knee* traducido como *eye*, *cruciate* como *cross-linked*, y lo que presumiblemente era *effusion* como *urinary growth*.

Un modelo entrenado sobre estas etiquetas aprende predominantemente de estudios redactados en inglés o español. Desplegado en un centro que informa en griego o búlgaro, su rendimiento real sería inferior al reportado y ninguna métrica agregada lo advertiría: un AUC macro de 0.708 no transparenta que la supervisión fue sistemáticamente peor para unos centros que para otros. El sesgo no está en el modelo sino en los datos que lo alimentan, lo que lo vuelve invisible a cualquier auditoría que examine únicamente las predicciones.

Existe además un límite no verificable: de los 4 349 estudios sin etiqueta dorada, 1 989 corresponden a los siete idiomas problemáticos y su calidad de etiqueta no admite medición, porque no hay verdad de referencia para ellos. Lo que este informe reporta se estima sobre los 30 estudios dorados no ingleses y se extrapola bajo el supuesto, no verificable, de que el extractor se comporta igual. La consecuencia práctica es que la validación local sería indispensable antes de operar en un centro cuyo idioma no estuviera bien representado.

## 7 Discusión crítica de las limitaciones

**Todo está medido sobre muestras chicas.** Los 56 estudios dorados producen un intervalo del 95 % de aproximadamente $\pm 0.05$ sobre el AUC macro, y de 0.30 en promedio por etiqueta individual; cada pliegue de la validación cruzada emplea 104 estudios con etiqueta débil. Eso fija el tamaño mínimo de efecto que este trabajo puede detectar, y explica por qué cinco de las siete comparaciones de la ablación quedan sin resolver: la diferencia entre las dos arquitecturas, por ejemplo, es de $-0.018$ con intervalo $[-0.098, +0.058]$, y afirmar que una supera a la otra sería interpretar ruido de muestreo como señal.

**Una conclusión que desapareció al fijar el entrenamiento.** Una versión anterior observaba que el ordenamiento entre las dos arquitecturas se invertía entre validación y prueba. Con el entrenamiento reproducible esa inversión no ocurre: ResNet-50 queda por delante en ambos conjuntos (0.724 y 0.646, contra 0.698 y 0.628). Es la Sección 5.5 en su forma más incómoda: la falta de reproducibilidad no solo contaminaba las comparaciones numéricas, también las observaciones cualitativas construidas sobre ellas.

**El 25.7 % de etiquetas incorrectas es un techo, y parte de él es irreducible.** Parte de ese ruido no se puede eliminar desde el texto: un informe que consigna *Moderate joint effusion* tiene la etiqueta de derrame en cero, y otro que menciona *osteochondral fracture* tiene la de fractura en cero, porque media criterio clínico: una fractura osteocondral en la faceta rotuliana se contabiliza como osteoartrosis patelofemoral. Ningún método basado solo en texto alcanzaría acuerdo perfecto. Sinovitis es el caso extremo: 8 de sus 17 positivos perdidos no mencionan nada sinovial en todo el informe, de modo que ampliar el léxico no la recupera.

**Sobre la agregación por atención no se puede concluir nada.** Queda por detrás del promedio simple en los dos conjuntos, pero el intervalo de la diferencia cruza cero. El enunciado pide implementar un componente cuyo aporte este trabajo no puede medir con 56 estudios de prueba.

**La activación es consistente en solo tres de doce hallazgos.** Medido sobre ocho estudios por hallazgo, la dispersión del centro de masa se mantiene por debajo de 0.20 sin ningún caso en el margen únicamente para el ligamento cruzado anterior, el menisco lateral y el derrame articular. En los nueve restantes la evidencia en que el modelo se apoya varía demasiado entre casos como para considerarla anatómicamente localizada, y todos presentan algún caso cuya activación cae en el borde de la imagen, fuera de la articulación.

## 8 Conclusiones

Tres resultados contradicen expectativas razonables de partida.

Primero, casi ninguna intervención del lado del modelo fue significativa: de las siete de la ablación, solo el preentrenamiento en ImageNet ($+0.084$) y el plano de la resonancia ($+0.056$). Del lado de las etiquetas, la detección de negación eliminó 29 de 112 falsos positivos sin perder un verdadero positivo.

Segundo, eso describe el régimen y no las arquitecturas: con 4 407 estudios en lugar de 576, ResNet-50 supera a Inception por 0.103 de AUC con intervalos que no se solapan. El empate del entregable #2 medía un conjunto demasiado pequeño para que el preentrenamiento rindiera. Comparar arquitecturas sin declarar el régimen no significa gran cosa.

Tercero, un entrenamiento en GPU no es reproducible por sembrar los generadores: dos corridas con la misma semilla llegaban a diferir 0.041 de AUC, por encima de cuatro de las siete comparaciones del estudio. Sobre esa base una versión anterior afirmaba que la atención era peor que el promedio; con los kernels fijados el efecto queda en $[-0.001, +0.128]$. Nada en el informe lo dejaba ver.

La limitación de fondo persiste: 56 estudios no distinguen efectos menores a 0.05 de AUC, y dos etiquetas (sinovitis y artrosis patelofemoral) rinden cerca del azar en los dorados pese a su desempeño en validación, lo que sugiere que el modelo aprendió a predecir al extractor y no al hallazgo.

## References


[1] Wendy W. Chapman, Will Bridewell, Paul Hanbury, Gregory F. Cooper, and Bruce G. Buchanan. A simple algorithm for identifying negated findings and diseases in discharge summaries. *Journal of Biomedical Informatics*, 34(5):301–310, 2001.

[2] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255, 2009.

[3] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[4] Maximilian Ilse, Jakub M. Tomczak, and Max Welling. Attention-based deep multiple instance learning. In *International Conference on Machine Learning (ICML)*, pages 2127–2136, 2018.

[5] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 1097–1105, 2012.

[6] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.

[7] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

[8] NLLB Team, Marta R. Costa-jussà, James Cross, Onur Çelebi, Maha Elbayad, Kenneth Heafield, Kevin Heffernan, et al. No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv:2207.04672*, 2022.

[9] Radiological Society of North America. Rsna knee abnormality detection. Kaggle, 2026. 819,640 archivos DICOM, 569.76 GB, 16 centros en cinco continentes. `https://www.kaggle.com/competitions/rsna-knee-abnormality-detection`.

[10] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. In *IEEE International Conference on Computer Vision (ICCV)*, pages 618–626, 2017.

[11] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.

[12] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1–9, 2015.